

# 2024年度 学术组会

学至无憾

导师：黄天羽 汇报人：罗巨鹏

北京理工大学数学表演与仿真技术北京市重点实验室





北京理工大学  
BEIJING INSTITUTE OF TECHNOLOGY

# 论文分享：超图推荐系统

Live streaming channel recommendation based on viewers' interaction behavior: A hypergraph approach

2024-09 Decision Support Systems IF-6.7 SCI-1

导师：黄天羽 汇报人：罗巨鹏



2024-09-09 计算机技术





余力\*

教授

中国人民大学 信息学院

大数据分析与应用、  
推荐系统与智能决策、  
金融科技与商务智能、  
在线直播与网络营、  
机器学习与数据挖掘



Wei Gong

硕士研究生

中国人民大学 信息学院

大数据分析、  
深度学习、  
推荐系统、  
自然语言处理



Dongsong  
Zhang

full professor

美 北卡罗来纳大学夏洛  
特分校 贝尔克商学院

社会计算、  
健康 IT、  
移动 HCI、  
商业智能和在线社区



01 引言和相关工作

02 观众行为理解  
与前置知识补充

03 VIBM-hyper模型

04 实验与评估

05 知识点扩展与反思

警告  
本文不是算法革新  
是新方法引入领域



# 01 引言和相关工作





## 研究背景、研究意义



北京理工大学  
BEIJING INSTITUTE OF TECHNOLOGY

### 客观事实：

近年来，直播流媒体因其实时交互特性而越来越受欢迎。观众可以通过发送虚拟礼物、弹幕等方式与直播主播交互。

### 问题挖掘：

面对海量的主播和频道，观众需要进行筛选。信息过载问题和频繁接触不感兴趣的频道，会影响用户体验。

### 相关研究：

众多研究者从视频帧和评论的关联性（内容分析）、观看历史建模（序贯决策）、用户和主播的交互行为以及行为路径（进入、停留、离开）设计了相关的直播流推荐系统。




存在不足：


1. 传统推荐系统基于传统图技术对交互建模，每条边仅连接2个节点，只能模拟点对点（观众与频道）的交互；
2. 单个用户和直播频道之间的交互次数相较于用户数量来说是稀疏的，进一步削弱了点对点交互信息的可靠性。

事实基础：

同一频道多个观众的相似交互行为可能代表相似偏好



传统推荐系统关注的交互关系



事实上的交互关系



用户和频道根据交互可以进行分组（多对多）：

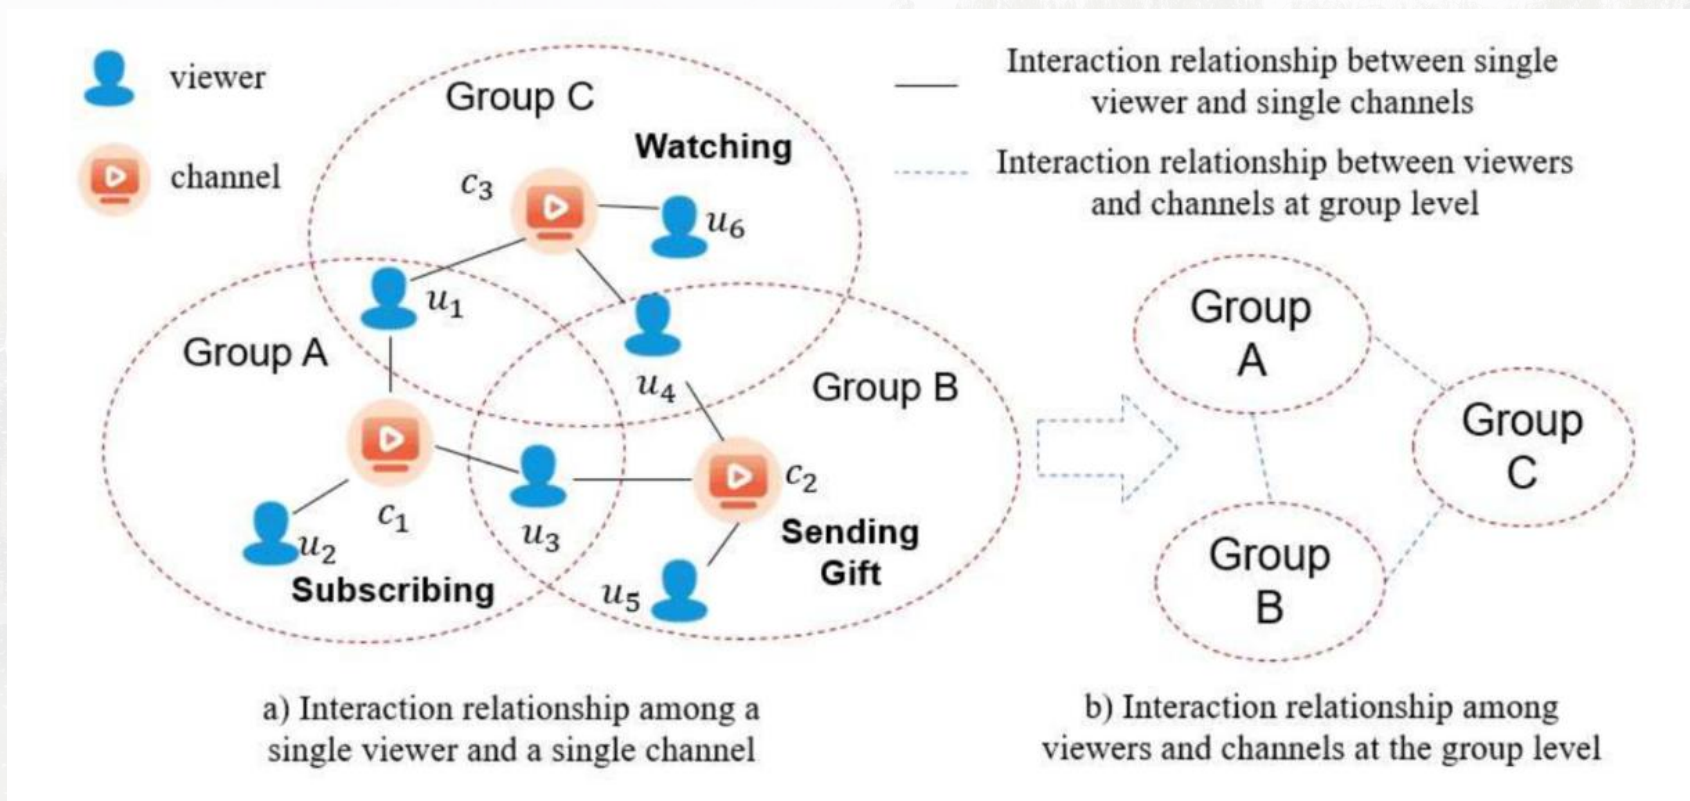



Fig. 1. Interaction relationship between viewers and channels at a single viewer/channel level and a group level.

单个用户关注多个频道，可以视作频道组。同样多个用户关注同一频道，可以视作用户组。通过对组进行关联和刻画，可以捕捉用户和频道之间的隐式关联。



方法引入：刻画多对多关系

- 超图是一种广义上的图，一条边（超边）可以连接任意数量的顶点
- 具有增强表征学习的效果，特别是在节点之间复杂关系的建模方面



研究目标：

1. 在群体层面上对直播平台上的用户与频道之间的关联关系进行建模，以进行频道推荐
2. 在群体层面上，基于用户与频道之间的交互，了解用户的偏好，并推荐相应的直播频道

贡献：

1. 新模型：提出了一种新的直播频道推荐模型VIBM-Hyper，首次探索本领域的超图技术；
2. 新建模：构建了两种新型的超图来增强用户和频道的表征；
3. 新模块：设计了超图卷积模块和行为意识注意模块，以生成用户和频道的有效表征。



### 直播频道（研究主题）：

- 先前研究表明，观众的行为与其对频道不同方面的**偏好**之间存在密切的关系（理论基础）。
- 频道中用户行为的研究有三个主要方向：社交需求分享、直播受欢迎程度预测、**用户推荐**。

### 基于行为的推荐（方法）：

利用观众的历史行为，通过预测用户对目标项目的潜在行为来增强推荐。

现有的基于行为的项目推荐工作可以根据行为的类型分为两类：

1. 对用户的单一交互行为进行建模，利用深度神经网络预测用户未来可能进行行为的概率；
2. 利用用户的多种交互类型来预测他们的行为。

### 超图学习（方法）：

1. 已经从算法研究应用到推荐系统，但是尚未应用于直播领域；
2. 可以捕捉复杂交互关系（多个用户和多个物品之间的交互关系）。



# 02 观众行为理解

与前置知识补充





## 数据准备:

- 抓取bilibili上: 1天内 200个频道 3000名观众 5000条行为记录/频道 5次观看/人 1小时/频道
- 频道类别: 游戏 唱歌 日常分享; 行为类别: 送礼物 发弹幕 观看频道内容 (未计时)。

分析1: 观众行为差异  
分析观众行为的平均频率。  
结论: 显著差异。




Fig. 2. The frequency distribution of viewer behaviors in different live streaming channels.



## 分析2：观众行为相关性

检验观众的某种行为是否与其他行为相关，  
为交互超图和感知注意力模块提供理论依据。

结论：

表面：购物者可能送礼，弹幕者可能订阅。

深层：不同的条件概率表明不同行为间相关性不同。

## 综合结论：

1. 不同频道观众行为的发生频率不同；
  2. 不同行为间有一定程度的相关性。
- 频道推荐时有必要考虑不同类型的交互行为，  
以捕获观众对频道不同方面的偏好。




Fig. 3. Visualization of Conditional Probabilities  $P(A|B)$  of Viewer Behaviors.



应用场景：

- 基于用户维度的推荐：根据用户的历史行为和兴趣进行推荐，比如淘宝首页的猜你喜欢、抖音的首页推荐等。
- 基于物品维度的推荐：根据用户当前浏览的物品进行推荐，比如打开拼多多的商品详情页，往下面滑动会推荐和主商品相关的商品。





# 03 VIBM-hyper模型



概念界定：

频道：  $c$  :channel=live streamer channel,  $C$  :一组 $c$ 的集合

观众：  $u$  :viewer,  $U$  :一组 $u$ 的集合

交互行为：  $b$  :behavior,  $B$  : $c$ 中所有 $u$ 的 $b$ 集合

$S$  是 $u$ 进行了 $b$ 的一组 $C$ 集合（交互历史）

行为子类：根据强度进一步划分，如送礼价值、弹幕数量

面向频道的行为组：CBG。表示 $u$ 对 $c$ 的共享偏好

面向观众的行为组：VBG。表示 $u$ 兴趣组之间的关系

面向频道的超图：CBH。

超边连接了在 $c$ 中进行了相同类型 $b$ 的 $u$ ，一个频道若干观众

面向观众的超图：VBH。

超边连接了那些 $u$ 进行了特定类型 $b$ 的 $c$ ，一个观众若干频道

Table 2

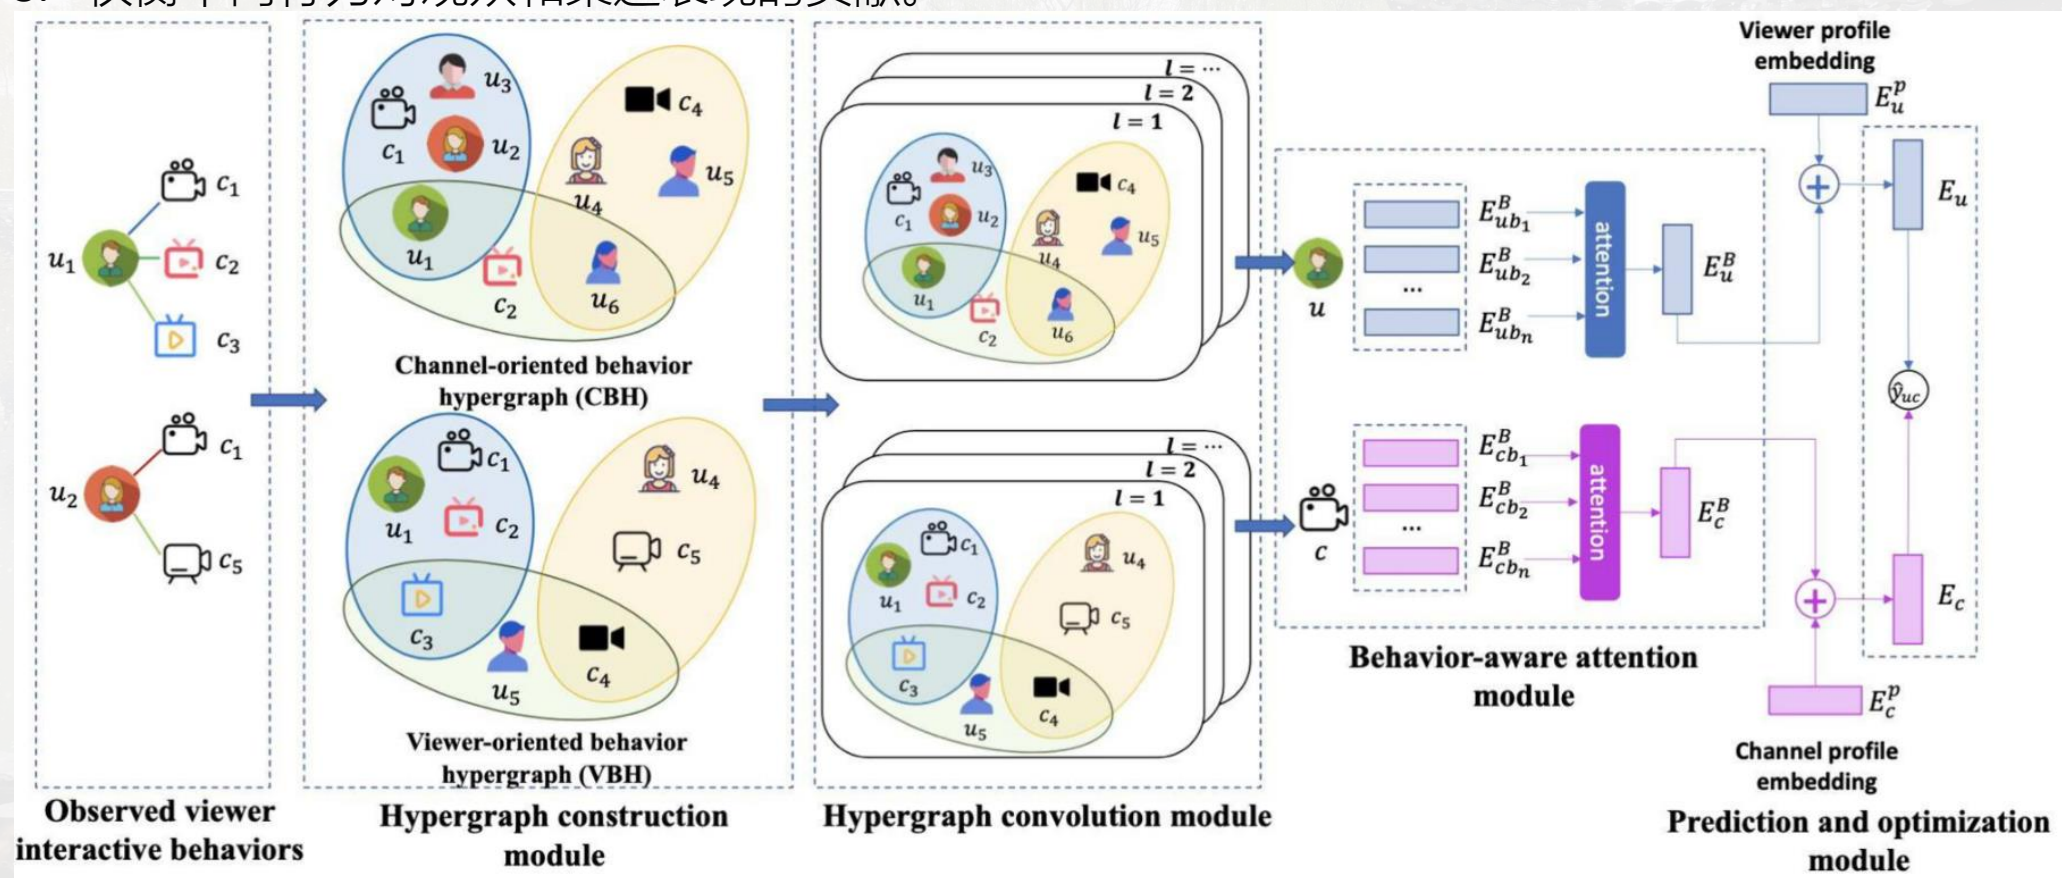
Notations and definitions.

| Notations | Concepts  |
|-----------|---|
| $U$       | The viewer Set  |
| $u$       | A viewer $u$  |
| $C$       | The live streaming channel Set                                |
| $c$       | A live streaming channel $c$                                  |
| $B$       | The viewer Behavior Set                                       |
| $b$       | A behavior $b$ and its corresponding behavior subcategories   |
| $S_u^b$   | History of interaction behaviors of viewer under behavior $b$ |
| $CBG_c^b$ | Channel-oriented Behavior Group (CBG)                         |
| $VBG_u^b$ | Viewer-oriented Behavior Group (VBG)                          |
| $CBH_c^b$ | Channel-oriented Behavior Hypergraph (CBH)                    |
| $VBH_u^b$ | Viewer-oriented Behavior Hypergraph (VBH)                     |
| $E_c$     | The final representation of channel $c$                       |
| $E_{cb}$  | The representation of channel $c$ based on behavior $b$       |
| $E_c^p$   | The profile embedding of channel $c$                          |
| $E_c^B$   | The behavior-aware embedding of channel $c$                   |
| $E_u$     | The final representation of viewer $u$                        |
| $E_u^p$   | The profile embedding of viewer $u$                           |
| $E_u^B$   | The behavior-aware embedding of viewer $u$                    |
| $d_c$     | The embedding dimension of $E_c$                              |
| $d_u$     | The embedding dimension of $E_u$                              |
| $n_{bs}$  | The number of behavior categories                             |



设计原理：

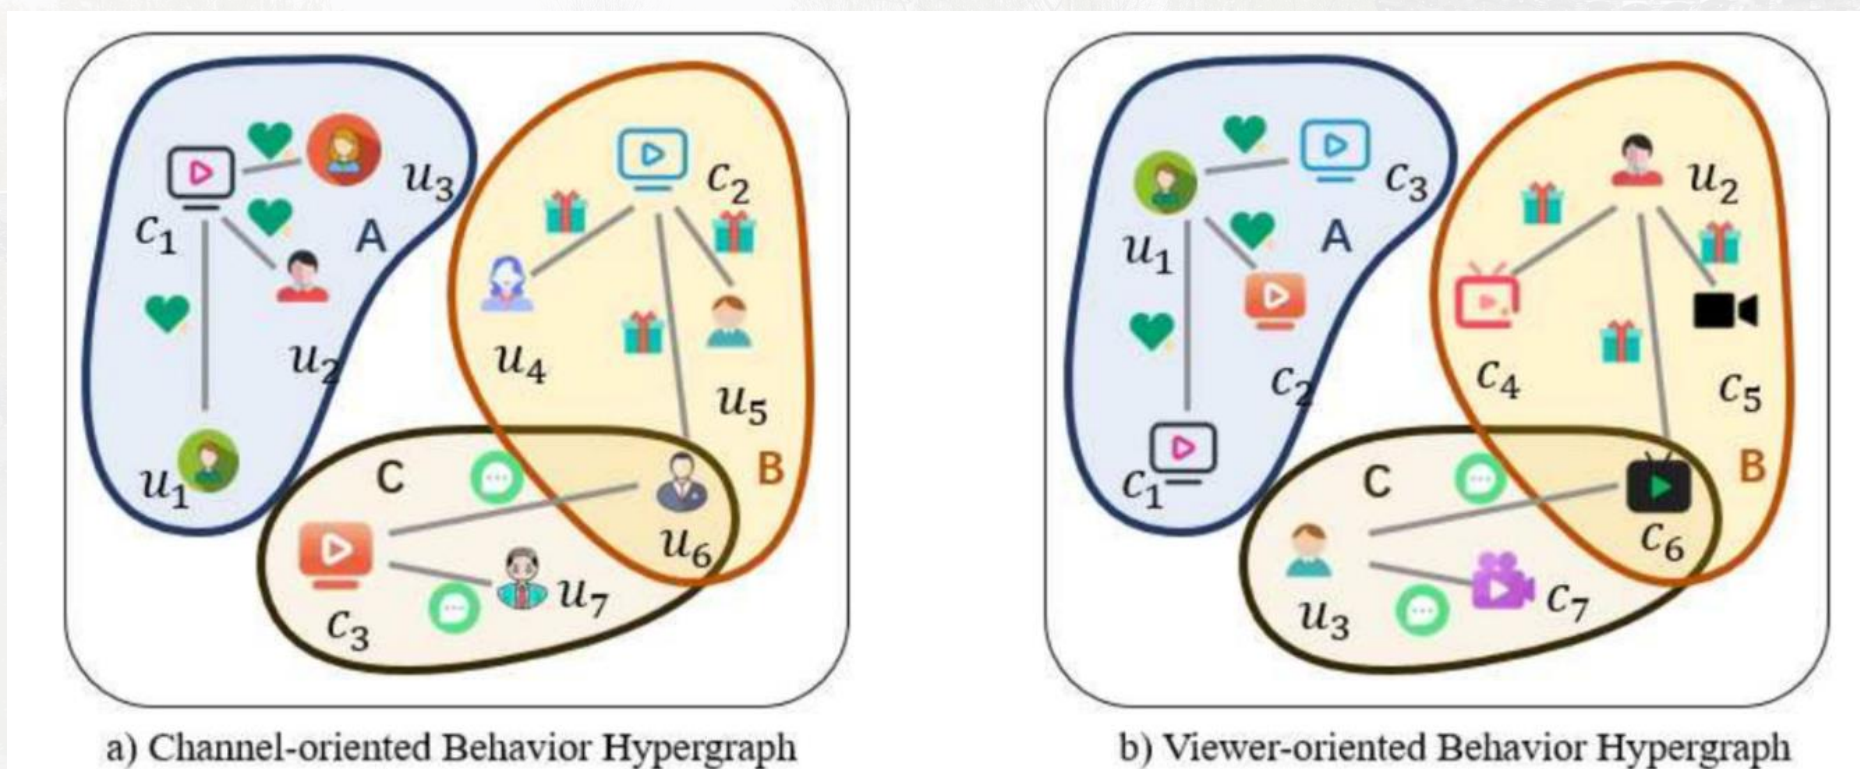
1. 在组级别捕获多观看者和多渠道之间的交互关系，以模拟观看者偏好。
2. 从渠道和观众的角度对观众的交互行为进行建模。
3. 权衡不同行为对观众和渠道表现的贡献。





通过行为集合  $S_u^b$  构建超图:

- 找出哪些  $u$  在  $c$  进行了相同的行为, 得到CBH 图a
- 直接基于  $S_u^b$  构建VBH 图b



**Fig. 5.** The Channel-oriented Behavior Hypergraph (CBH) and Viewer-oriented Behavior Hypergraph (VBH).

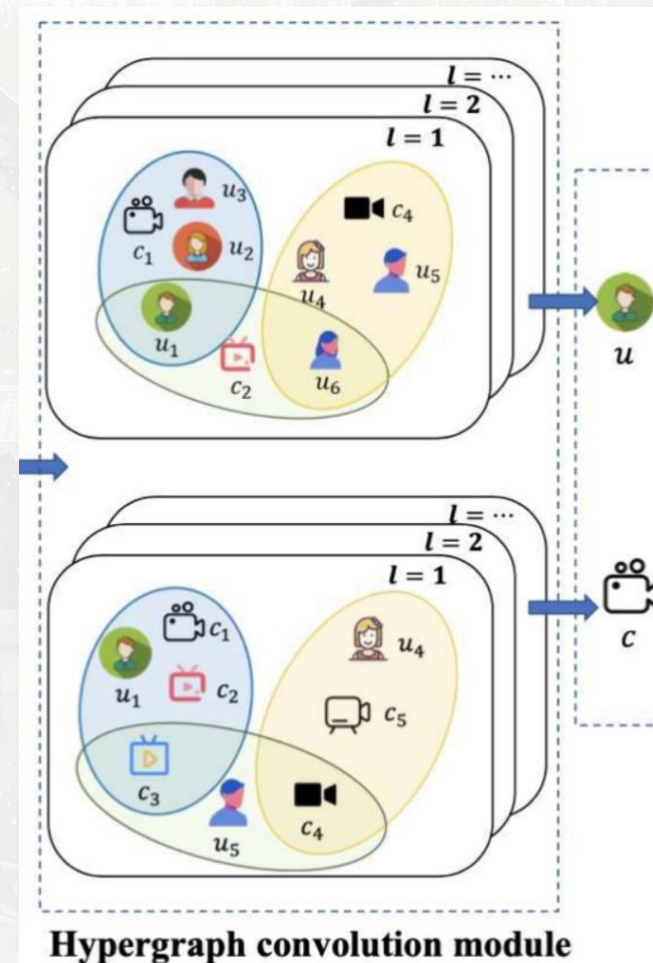


使用谱超图卷积方法 对超图进行卷积：获得频道和观众的表征

- 生成超图关联矩阵  $H$  (Incidence Matrix), 馈送到超图卷积网络。

$$\bullet \quad X^{(l+1)} = \sigma \left( D_v^{-\frac{1}{2}} H W D_e^{-1} H^T D_v^{-\frac{1}{2}} X^{(l)} \Theta^{(l)} \right)$$

$\sigma$       激活函数  
 $X$       节点嵌入矩阵  
 $D_v \ D_b$     顶点和超边的度矩阵  
 $H$       关联矩阵  
 $\Theta$       层之间的权重矩阵

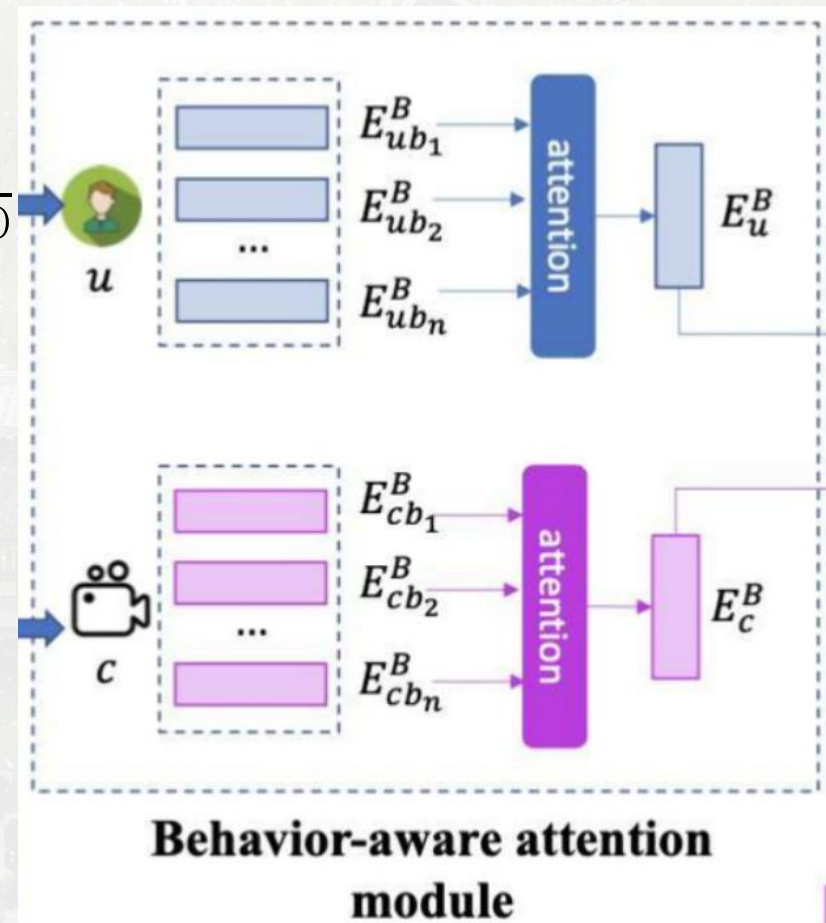




部署一种自注意力机制来推导：behavior-aware的频道和观众的表征

- 频道c的平均特征： $\bar{E}_c^B = \frac{1}{|B|} \sum_b E_{cb}^B$
- 行为-频道相关性分数： $s(b, c) = E_{cb}^{B^T} \cdot \bar{E}_c^B$
- 内部注意力权重： $w(b, c) = \text{softmax}(s(b, c)) = \frac{\exp s(b, c)}{\sum_{b \in B} \exp s(b, c)}$
- 频道c的最终表征： $E_c^B = \sum_{b \in B} w(b, c) \cdot E_{cb}^B$

$|B|$  观众行为总数  
 $E_{cb}$  超图卷积生成的频道表示  
 注意 均在行为感知B的前提下





静态表征：观众profile；频道类型、标题、描述

固定不变的

动态表征：基于行为的（超图卷积+注意力）表征

随观众变化

- Word2Vec图嵌入向量：  $E_u^p$   $E_c^p$
- 最终表征：  $E_u = E_u^p + E_u^B$ ,  $E_c = E_c^p + E_c^B$
- 观众-频道相关性分数：  $\hat{y}_1(u, c) = \frac{E_u \cdot E_c}{\|E_u\| \cdot \|E_c\|}$
- 频道-历史交互频道相关性分数：  $\hat{y}_2(u, c) = \sum_{b^* \in B} \sum_{c_j \in N_{b^*}(u)} E_{cb^*}^{B^T} \cdot M_{b^*} \cdot E_{c_j b^*}^B$
- 评分函数（总相关性分数）：  $\hat{y}(u, c) = \lambda \cdot \hat{y}_1(u, c) + (1 - \lambda) \hat{y}_2(u, c)$

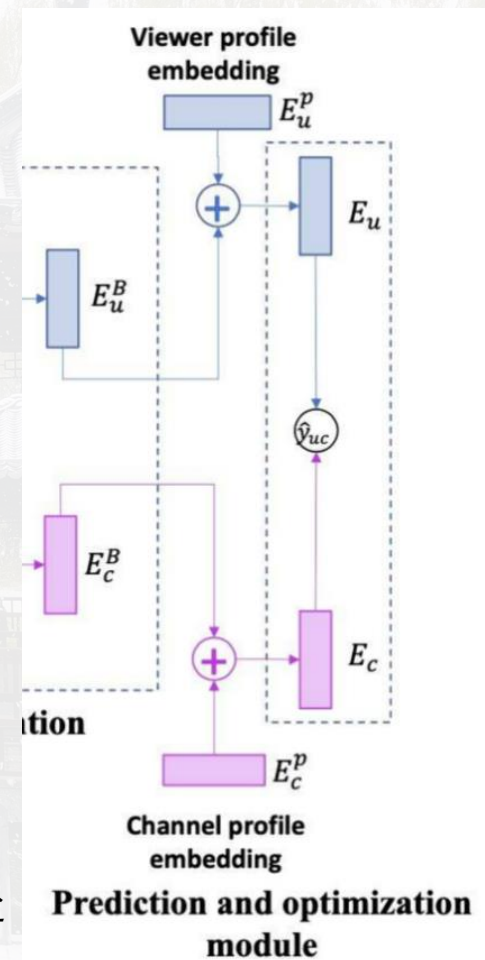
$\hat{y}_1(u, c)$  衡量候选频道u对观众c的兴趣程度（余弦相似度）

$\hat{y}_2(u, c)$  衡量候选频道u与观众c交互过的历史频道的相似性，  $N_{b^*}(u)$ 观众u执行过行为 $b^*$ 的频道集合，  $M_{b^*} \in R^{d' \times d'}$ ,  $d' = d \times (L + 1)$ 度量发生行为 $b^*$ 的两个频道间的相关性矩阵

$d$  嵌入向量的维度，决定每个节点在向量空间中表示的丰富程度

$L$  超图卷积的层数  $L$ ，影响信息在超图结构中传播的深度

$d'$  允许在计算相关性时考虑到从输入层到卷积的每层变换。即不仅能够处理原始的嵌入空间，还能够处理经过超图卷积变换后的空间。





为了学习超参数，用贝叶斯个性化排序( BPR )损失来**优化**VIBM - Hyper模型：  
强调观察到的用户-项目交互和未观察到的用户-项目交互之间的**相对顺序**，正样本应该被赋予比负样本更高的预测评分以更好地学习观众偏好：

- parawise的损失函数： $Loss = \sum_{(u,c,c') \in O} -\ln \sigma(\hat{y}(u,c) - \hat{y}(u,c')) + \beta \cdot \|\Theta\|^2$


$O = \{(u, c, c') | (u, c) \in S^+, (u, c') \in S^-\}$  一组目标 行为训练数据（成对儿）

$S^+ S^-$  观察/未观察到的交互集合（即交互历史中没有）

$\sigma$  Sigmoid函数

$\beta$   $L_2$ 正则化系数，防止过拟合

$\Theta$  所有可训练的参数





# 04 实验与评估





提出问题：

- 与最先进的模型相比，VIBM-Hyper在推荐直播频道方面表现如何？（纵向）
- 观众的多种交互行为是否比单一交互行为更能提高频道推荐的性能？（横向）
- 与非基于超图的基线方法相比，超图建模方法是否有助于VIBM-Hyper提高通道推荐的性能？（消融）



| 网站   | 内容   | 观众数     | 频道数  | 交互数       | 人均观看 | 稀疏度    | 记录时长 | 频道类数 | 行为类数 |
|------|------|---------|------|-----------|------|--------|------|------|------|
| B站V区 | 虚拟直播 | 21,040  | 1040 | 163,200   | 7    | 99.25% | 31天  | 3    | 3    |
| 蘑菇街  | 购物直播 | 186,539 | 2620 | 7,165,582 | 38   | 99.99% | 19天  | 3    | 4    |



回答问题：

- 选择6个单行为基线模型和5个多行为基线模型（包括一个超图）
- 把数据集划分为质保函某种行为的若干子集
- 把超图构造模块替换成传统图结构



**Table 6**

Comparisons results with the Bilibili-VTuber.

| Categories             | Methods    | TopK = 20    |              | TopK = 40    |              | TopK = 80    |              |
|------------------------|------------|--------------|--------------|--------------|--------------|--------------|--------------|
|                        |            | Recall       | NDCG         | Recall       | NDCG         | Recall       | NDCG         |
| Single-behavior models | UPC        | 0.040        | 0.012        | 0.059        | 0.020        | 0.084        | 0.031        |
|                        | LiveRec    | 0.059        | 0.013        | 0.069        | 0.028        | 0.091        | 0.034        |
|                        | ADARM      | 0.044        | 0.016        | 0.071        | 0.028        | 0.099        | 0.032        |
|                        | n-MSN      | 0.053        | 0.010        | 0.069        | 0.030        | 0.103        | 0.033        |
|                        | DHCN       | 0.063        | 0.011        | 0.075        | 0.030        | 0.105        | 0.036        |
|                        | LightGCN   | 0.060        | 0.010        | 0.072        | 0.029        | 0.104        | 0.034        |
|                        | NMTR       | 0.045        | 0.017        | 0.080        | 0.030        | 0.109        | 0.038        |
| Multi-behavior models  | MC-BPR     | 0.065        | 0.018        | 0.079        | <b>0.037</b> | 0.108        | 0.040        |
|                        | GraphSAGE  | 0.062        | 0.022        | 0.081        | 0.031        | 0.108        | 0.039        |
|                        | MBGCN      | <b>0.069</b> | <b>0.023</b> | <b>0.092</b> | 0.035        | <b>0.114</b> | <b>0.041</b> |
|                        | DualHGCN   | 0.065        | 0.022        | 0.088        | 0.033        | 0.110        | 0.038        |
|                        | VIBM-Hyper | <b>0.082</b> | <b>0.031</b> | <b>0.103</b> | <b>0.040</b> | <b>0.121</b> | <b>0.046</b> |
| Improvement            |            | 18.98% *     | 32.79% **    | 10.4% ***    | 9.28% **     | 6.32% ***    | 13.01% ***   |

Note: 1)\* $p < 0.1$ , \*\* $p < 0.05$ , \*\*\* $p < 0.01$ ; 2) The last line is the percentage improvement achieved by VIBM-Hyper over the best baseline method marked in bold and italics.

**Table 7**

Performance of VIBM-Hyper w.r.t different behaviors.

| Methods       | Bilibili-VTuber |              | MOGU         |              |
|---------------|-----------------|--------------|--------------|--------------|
|               | Recall@20       | NDCG@20      | Recall@20    | NDCG@20      |
| VIBM-Hyper    | <b>0.082</b>    | <b>0.031</b> | <b>0.061</b> | <b>0.027</b> |
| VIBM-Hyper_CS | 0.075           | 0.019        | 0.040        | 0.012        |
| VIBM-Hyper_GP | 0.077           | 0.026        | 0.050        | 0.021        |
| VIBM-Hyper_DF | 0.072           | 0.021        | 0.044        | 0.017        |

**Table 8**

Results for Ablation Test of hypergraphs under Recall@20/NDCG@20.

| Architecture          | Bilibili-VTuber |              | MOGU         |              |
|-----------------------|-----------------|--------------|--------------|--------------|
|                       | Recall@20       | NDCG@20      | Recall@20    | NDCG@20      |
| (1) VIBM-Hyper        | <b>0.082</b>    | <b>0.031</b> | <b>0.061</b> | <b>0.027</b> |
| (2) Remove hypergraph | 0.064           | 0.020        | 0.052        | 0.019        |



补充研究：

- 评估Hypergraph 卷积层的数量对推荐性能的影响

卷积层数为1：只聚合邻居节点信息，效果不佳；

卷积层数从1到3：从多种行为中有效地学习观众的偏好，性能提升；

卷积层数从3到5：添加更多层可能会导致模型过度拟合。过多参数可能会使模型学到噪声和特定但不需要的细节。

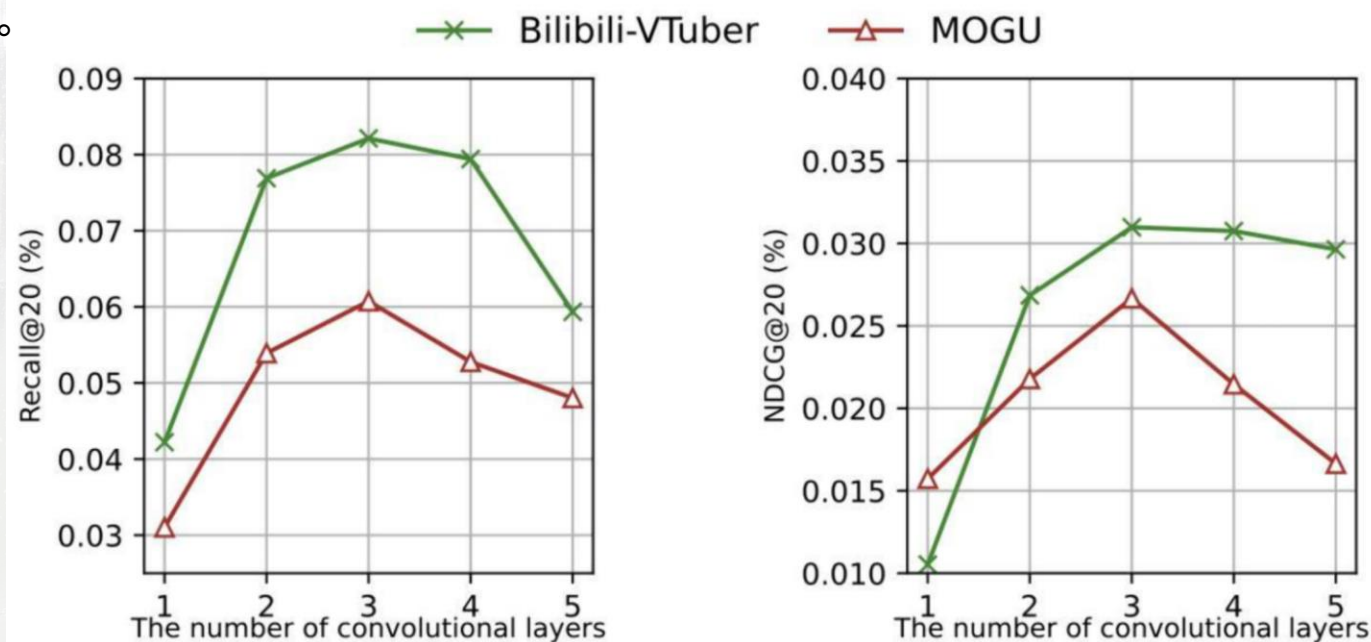


Fig. 6. Performance comparison with different numbers of hypergraph convolutional layers.



# 05

## 知识点扩展与反思



为什么整体性能评估不用Accuracy指标或ROC曲线？


| 指标  | 公式                                  | 含义                        | 场景                                      |
|---|-------------------------------------|---------------------------|---|
| 查全率 (Recall)<br>真阳性率TPR、敏感性 (Sensitivity) | $\frac{TP}{TP + FN}$                | 所有真正为正例的样本中，被模型预测为正例的样本占比 | 尽可能多地找出所有相关信息的场景，如医疗诊断中的疾病筛查、信息检索中的全面搜索 |
| 查准率 (Precision)                           | $\frac{TP}{TP + FP}$                | 所有预测为正例的样本中，真正为正例的样本占比    | 需要确保预测结果准确性的场景，如法律判决、金融风险评估             |
| 准确率 (Accuracy)                            | $\frac{TP + TN}{TP + TN + FP + FN}$ | 所有样本中，被正确预测的样本占比          | 对模型整体性能进行综合评价，正负样本分布较为均衡的场景             |

| 指标                                    | 公式   | 含义                                    | 场景  |
|---------------------------------------|--|---------------------------------------|---|
| 累积增益<br>(Cumulative Gain)             | $CG_p = \sum_{i=1}^p rel_i$                                | 只关注搜索结果列表中所有结果的相关性得分的总和               | 能够反映搜索结果页面的总体质量，但无法评估算法的排序能力                  |
| 折损累积率<br>(Discounted Cumulative Gain) | $DCG_p = rel_i + \sum_{i=1}^p \frac{rel_i}{\log_2(i + 1)}$ | 排名越靠前的对指标的影响越大，当相关度高的排序位置靠后时进行惩罚      | 考虑了结果的位置信息，更准确地评估排序算法的性能，常用于搜索引擎、推荐系统等领域的算法评估 |
| 归一化累积增率<br>(Normalized DCG)           | $NDCG_p = \frac{DCG_p}{IDCG_p}$                            | IDCG是理想情况下DCG值，此时所有结果按照相关性得分从高到低排序且最大 | 通过对DCG进行归一化处理，使其能够在不同长度的搜索结果或不同用户之间进行比较       |





Multi-Head Attention




| self(intra) attention 编码器 解码器 | inter(cross) attention 解码器           |
|-------------------------------|--------------------------------------|
| 序列内部                          | 数据源之间或跨模态                            |
| 查询、键和值都来自同一个输入序列              | 查询来自一个输入序列，而键和值来自另一个输入序列             |
| 捕捉序列内部的长距离依赖关系<br>文本分类、情感分析   | 根据查询意图，平衡不同数据源或模态之间的重要性<br>机器翻译、问答系统 |

按注意力  
添加位置：

| local attention 解码器   | global attention 解码器 |
|-----------------------|----------------------|
| 编码器的部分位置              | 编码器的所有位置             |
| 根据目标位置选择上下文窗口，关注窗口内状态 | 每个时间步都关注所有隐藏状态       |
| 减少计算量，提高处理长序列的效率      | 充分利用序列中的所有信息，计算量大    |

按特征采  
样方式：

| soft attention | hard attention |
|----------------|----------------|
| 反向传播时基于梯度进行优化  | 不能优化           |
| 确定性、参数化、可导     | 随机采样（蒙特卡洛），不可微 |
| 深度学习           | 强化学习           |






超图定义:  $G = (V; E; W)$

相邻、关联: 若  $\{x\}$  是超边, 则  $x$  与自身相邻

- 两个顶点是相邻的(adjacent): 存在包含两个顶点的超边
- 两个超边是关联的(incident): 两个超边的交点不为空
- 顶点的度:  $d(v_i) = \sum_{e_i \in E | v_i \in e_i} w(e_i)$  包含该顶点的超边的个数
- 超边的度:  $\delta(e_i) = |e_i| = \sum_{v_i \in V} h(v_i, e_i)$  超边上包含的顶点的个数

关联矩阵和邻接矩阵:

- $V = \{v_1, v_2, \dots, v_n\}$   $E = \{e_1, e_2, \dots, e_m\}$  并且  $\bigcup_{i \in I} e_i = V$  (没有孤立顶点)
- $n \times m$  关联矩阵  $\mathbf{H} = (h_{ij})$   $h_{ij} = \begin{cases} 1, & v_i \in e_j \\ 0, & \text{others} \end{cases}$
- 定义邻接矩阵:  $\mathbf{A} = \mathbf{H}\mathbf{H}^T$
- $n \times n$  邻接矩阵  $\mathbf{A} = (a_{ij})$  即节点  $i$  和  $j$  共享超边的数量



|       | $x_1$ | $x_2$ | $x_3$ | $x_4$ | $x_5$ |
|-------|-------|-------|-------|-------|-------|
| $e_1$ | 1     | 1     | 1     | 0     | 0     |
| $e_2$ | 0     | 0     | 1     | 1     | 0     |
| $e_3$ | 1     | 1     | 0     | 0     | 1     |

|       | $x_1$ | $x_2$ | $x_3$ | $x_4$ | $x_5$ |
|-------|-------|-------|-------|-------|-------|
| $x_1$ | 2     | 2     | 1     | 0     | 1     |
| $x_2$ | 2     | 2     | 1     | 0     | 1     |
| $x_3$ | 1     | 1     | 2     | 1     | 0     |
| $x_4$ | 0     | 0     | 1     | 1     | 0     |
| $x_5$ | 1     | 1     | 0     | 0     | 1     |



本文:

- 定义邻接矩阵:  $A = HWD_e^{-1}H^T$
- $n \times n$  邻接矩阵  $A = (a_{ij})$   $a_{ij} = w(e_n)$   $v_i, v_j \in e_n$  即节点  $i$  和  $j$  共享超边的加权求和
- 对角的  $m \times m$  权重矩阵  $W$  对角线的元素表示每条超边的权重  $w(e)$
- 对角的  $n \times n$  度矩阵  $D_v$  对角线的元素表示顶点的度
- 对角的  $m \times m$  度矩阵  $D_e$  对角线的元素表示超边的度

图卷积:  $X^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} X^{(l)} \Theta^{(l)})$   $\tilde{A} = A + I$

超图卷积:  $X^{(l+1)} = \sigma(D_v^{-\frac{1}{2}} H W D_e^{-1} H^T D_v^{-\frac{1}{2}} X^{(l)} \Theta^{(l)})$

图片卷积:  $(f * g)(x, y)$  使用滤波器  $g$  来对某个空间区域的像素点进行加权求和, 得到新的特征表示

图卷积: 根据拓扑结构  $g$  通过传播函数或聚合函数, 将邻居节点的信息聚合到当前节点上, 得到新的特征表示

|   |   |   |   |   |               |               |               |               |               |
|---|---|---|---|---|---------------|---------------|---------------|---------------|---------------|
| 2 | 2 | 1 | 0 | 1 | $\frac{2}{3}$ | $\frac{2}{3}$ | $\frac{1}{3}$ | 0             | $\frac{1}{3}$ |
| 2 | 2 | 1 | 0 | 1 | $\frac{2}{3}$ | $\frac{2}{3}$ | $\frac{1}{3}$ | 0             | $\frac{1}{3}$ |
| 1 | 1 | 2 | 1 | 0 | $\frac{1}{3}$ | $\frac{1}{3}$ | $\frac{5}{6}$ | $\frac{1}{3}$ | 0             |
| 0 | 0 | 1 | 1 | 0 | 0             | 0             | $\frac{1}{3}$ | $\frac{1}{3}$ | 0             |
| 1 | 1 | 0 | 0 | 1 | $\frac{1}{3}$ | $\frac{1}{3}$ | 0             | 0             | $\frac{1}{3}$ |



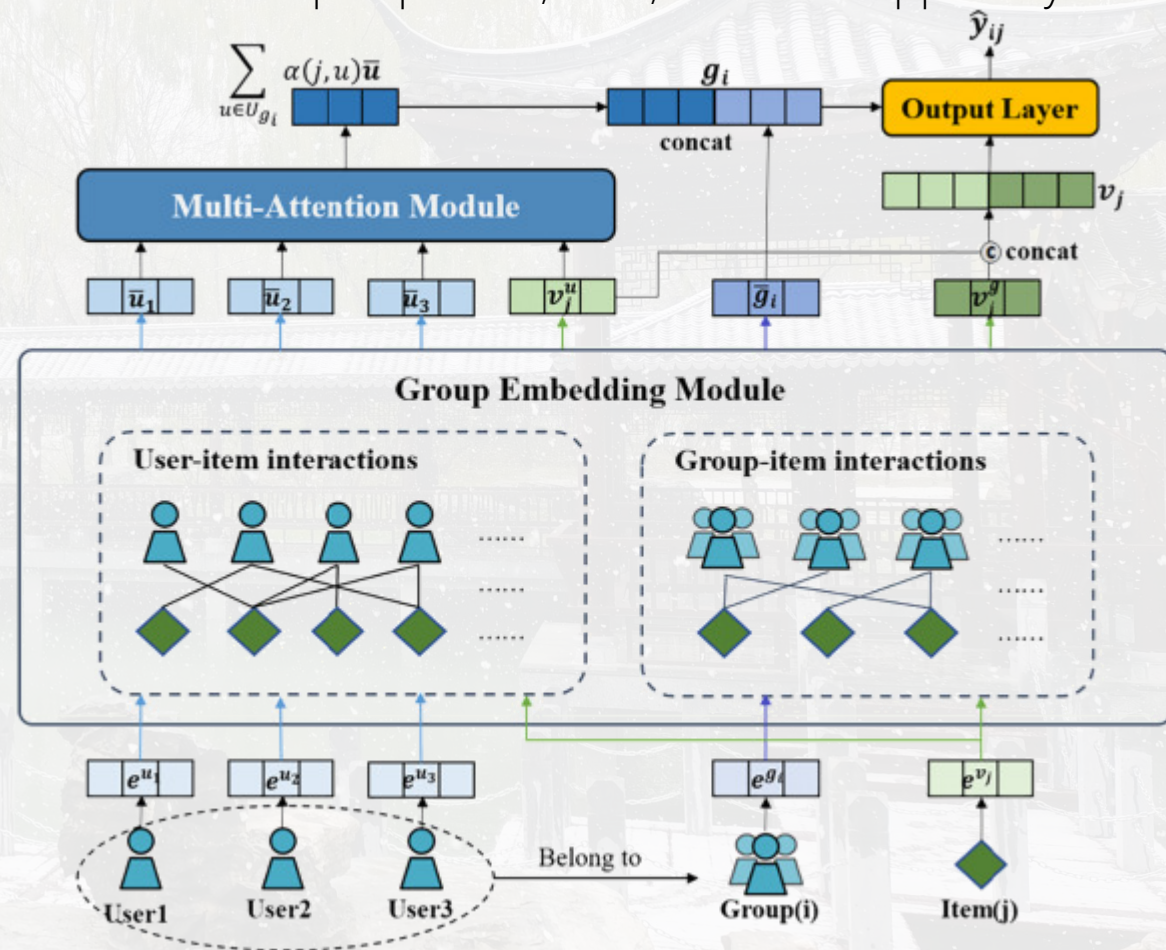
传统图能做的，超图没必要做：前置工作=>

- 组间建模问题：
  - 多对多
  - 高阶交互
- 数据稀疏性问题：
  - 通过间接连接来缓解冷启动难题

本文局限性：

- 模型主要依赖于直播频道的标题来获得其初始表示
- 需要挖掘更多观众的隐性行为，如观众在特定直播频道的停留时间，以更准确地捕捉观众的偏好
- 考虑不同直播者之间的社会关系，从直播者的角度更好地代表不同的直播渠道

Collaborative group embedding and decision aggregation based on attentive influence of individual members: A group recommendation perspective, 2023, Decision Support Systems







# THANKS FOR LISTENING

## 请老师同学们批评指正!

---

汇报人：罗巨鹏

**北京理工大学**  
BEIJING INSTITUTE OF TECHNOLOGY