



北京理工大学
BEIJING INSTITUTE OF TECHNOLOGY

知识组织与主题建模

Knowledge Organization & Topic Modeling

汇报人：罗巨鹏



20260610 计算机技术

目录

北京理工大学
BEIJING INSTITUTE OF TECHNOLOGY

01

知识组织概述

Knowledge Organization

02

主题模型发展

Topic Modeling

03

投稿经历分享

Experience Sharing

04

学术写作交流

Academic Writing

01 知识组织概述

Knowledge Organization



Knowledge Organization (KO)

Overview




What is Knowledge Organization?

Knowledge organization is the systematic arrangement, classification, and management of information to facilitate retrieval, understanding, and use across various domains.

1 Definition & Scope

- Methods and systems used to structure, classify, and manage knowledge
- Encompasses universal and domain-specific contexts
- Includes classification schemes, thesauri, indexing systems, etc.
- Goal: make information accessible, understandable, and usable



2 Methodologies



Concept-Analytical

Break knowledge into fundamental units



Concept-Synthetical

Integrate knowledge into coherent structures



Quantitative & Qualitative Approaches



Manual & Automated Methods



Support indexing, retrieval, data reduction, and decision making

3 Applications



Information Retrieval

Enhances search efficiency in libraries, databases, and digital repositories.



Classification & Indexing

Organizes documents, datasets, and digital content for easier access.



Education & Training

Teaches principles of classification, terminology, and knowledge management.



Research & Analysis

Supports theoretical studies, data analysis, and knowledge discovery.

4 Historical Evolution



Early Classification Efforts



Print Era (1970s–1990s)



Digital Transition (2000s–2010s)



Digital & Automated Systems (2010s–Present)

From manual classification to intelligent, digital, and automated knowledge organization systems.

5 Key Takeaways



Essential for efficient information management and retrieval



Integrates theoretical, practical, and technological approaches



Supports research, education, and professional practice in information science




Continuously evolving with digital technologies and automated systems

02 主题模型发展

Topic Modeling



Topic Modeling Evolution Aligned with NLP Milestones



组别	Metaphysics (形而上学: 现实假设)	Ontology (本体论: 实体与主题表示)	Epistemology (认识论: 知识获取与证成)	Formal Logic (形式逻辑: 自洽性)
1. 代数/矩阵分解类 (LSA, NMF)	现实是线性、可还原的低维结构 (固定本质维度, 噪声+高维投影)	实体: 词、文档、潜在因子 主题 = 固定权重向量 (线性/非负组合)	提取: 通过一次性数学分解 (SVD/NMF) 证成: 靠重构误差	优: 高度自洽 (线性代数公理) 劣: 假设矩阵低秩, 简化语言复杂性, 词袋假设简化现实
2. 概率图模型类 (pLSA, LDA)	现实是概率生成的过程 (随机采样驱动, 存在隐藏生成规律)	实体: 文档(θ)、主题(z)、词(w)、先验(α, β) 主题 = 词的概率分布 (Dirichlet控制)	提取: 通过贝叶斯推理 (Gibbs/Variational) 更新信念 证成: Perplexity + Coherence	优: 极强概率逻辑闭环 (生成故事+后验) 劣: 词袋假设简化现实
3. 神经/深度学习类 (VAE-based NTM, NVDM, ETM)	现实是深度非线性、可优化函数空间 (复杂模式涌现)	实体: 潜变量向量、网络参数 主题 = 潜空间中的区域/方向 (端到端学出, 事后提取)	提取: 通过端到端梯度优化 (ELBO等) 学习 证成: 重建质量 + 下游任务	优: 端到端优化框架严谨 劣: 主题定义较松散, 依赖经验解释
4. 嵌入-聚类-表示类 (Top2Vec, BERTopic)	现实是连续的语义向量空间 (几何关系、分布式表征)	实体: 嵌入向量、聚类簇 主题 = 嵌入空间中的聚类 + TF-IDF权重词列表 (事后提取)	提取: 通过预训练嵌入 + 聚类发现潜在空间结构 证成: 聚类质量 + 主题质量	优: 模块化流水线逻辑, 灵活 劣: 错误传递、上游依赖; 接口处可能不完全一致
5. LLM主题建模类 (Prompt-based, TopicGPT)	现实是语言中心、可叙述的知识投射 (LLM已编码的世界理解)	实体: 文档、LLM内部知识 主题 = 自然语言对象 (名字 + 详细描述 + 证据引用)	提取: 通过提示工程 + 上下文学习直接查询 证成: 人类判断 + 可验证引用	优: 对话式/启发式逻辑, 灵活且可解释 劣: 稳定性依赖提示词, 幻觉

1. 代数/矩阵分解类 (LSA, NMF) 现实是线性、可还原的低维结构 (固定本质维度, 噪声+高维投影)

实体: 词、文档、潜在因子
主题 = 固定权重向量 (线性/非负组合)

提取: 通过一次性数学分解 (SVD/NMF)
证成: 重构误差

优: 高度自治 (线性代数公理)
劣: 假设矩阵低秩, 简化语言复杂性, 词袋假设简化现实

$$A \approx U \Sigma V^T (\text{LSA} / \text{SVD})$$

$$A \approx WH (\text{NMF}, A \geq 0, W \geq 0, H \geq 0)$$

tf-idf score

occurrences of term in document

total documents

documents containing word

知乎 @ 倔强的李狗蛋

• A : 原始词-文档矩阵 (一个很大的二维表格)。行 = 所有词, 列 = 所有文档, 格子中的值 = 该词在该文档中出现的次数 (或TF-IDF权重)。

• U : 左奇异矩阵, 表示词与潜在主题的关系 (每个列是一个潜在维度/主题)。

• Σ : 奇异值对角矩阵 (一个只有对角线有数的矩阵), 数值越大表示该维度越重要 (用于排序和降维)。

• V^T : 右奇异矩阵的转置, 表示文档与潜在主题的关系。


• W : 主题-词矩阵 (非负), 行 = 主题, 列 = 词, 值 = 该词对该主题的重要程度 (权重)。

• H : 文档-主题矩阵 (非负), 行 = 文档, 列 = 主题, 值 = 该文档中各主题的比例。

• 约束: W 和 H 中所有元素 ≥ 0 (不能出现负数)。

代数 / 矩阵分解类：LSA (SVD) 与 NMF 的原理示意图

LSA (基于SVD)



原始数据：
高维词频/TF-IDF矩阵



降维到 k 维潜在主题空间
(捕获主要语义结构)




在主题空间表示文档
(每篇文档的主题坐标)



再映射回原空间
近似重构原始矩阵

NMF (非负矩阵分解)



原始数据：
高维词频/TF-IDF矩阵



apple data health
learn model virus
algorithm science cell
system network ...

W 的每一列 = 一个主题
(主题由哪些词构成)



H 的每一列 = 一篇文档的
主题分布 (由哪些主题构成)



用 $W \times H$ 近似重构
原始矩阵

NMF 约束

$$W \geq 0$$

$$H \geq 0$$



结果更可解释
(部分性、加性)



2. 概率图模型类 (pLSA, LDA)

现实是**概率生成的过程**
(随机采样驱动, 存在隐藏生成规律)

实体: 文档(θ)、主题(z)、词(w)、先验(α, β)
主题 = 词的概率分布 (Dirichlet控制)

提取: 通过**贝叶斯推理**
(Gibbs/Variational) 更新信念
证成: Perplexity + Coherence

优: 极强概率逻辑闭环 (生成故事+后验)
劣: 词袋假设简化现实

$$\theta_d \sim \text{Dir}(\alpha), \text{ for } d \in D$$

$$z_n \sim \text{Multi}(\theta_d), \text{ for } n \in [1, N_d]$$

$$w_n \sim \text{Multi}(\varphi_{z_n}), \text{ for } n \in [1, N_d]$$

$$\varphi_k \sim \text{Dir}(\beta), \text{ for } k \in K$$

- θ_d : 第 d 篇文档的主题混合比例 (一个概率向量, 总和=1)。
- $\sim \text{Dir}(\alpha)$: 服从 Dirichlet 分布 (一种控制概率向量“集中程度”的先验分布)。 α 是**超参数**, 越小越倾向于文档只用少数几个主题。
- $d \in D$: 对所有文档 D 中的每一篇文档 d 。
- $k \in K$: 对所有主题 K 中的每一个主题 k 。
- z_n : 文档中第 n 个词的主题分配 (它属于哪个主题)。
- $\sim \text{Multi}(\theta_d)$: 服从 Multinomial 分布 (多项分布), 根据文档的主题 θ_d 随机抽取一个主题。
- w_n : 文档中第 n 个词 (实际观察到的词汇)。
- $\sim \text{Multi}(\beta_{z_n})$: 根据当前主题 z_n 对应的词分布 β 随机生成这个词。
- φ_k : 每个主题的词概率分布 (主题-词矩阵),
- $\sim \text{Dir}(\beta)$: 服从 Dirichlet 先验分布, 由 β 超参数控制。
- N_d : 第 d 篇文档的词总数。

LDA 的生成过程 (以一篇文档 d 为例)

1. 主题 - 词分布 (全局)




2. 文档的主题混合比例

文档 d 的主题比例 $\theta_d \sim \text{Dir}(\alpha)$



$\theta_d = [0.6, 0.3, 0.1]$
(每篇文档由多个主题按比例混合)

3. 逐词生成 (文档 d 中的 N_d 个词)




$$p(z, \theta, \beta | w) = \frac{p(w | z, \beta) p(z | \theta) p(\theta) p(\beta)}{p(w)}$$

4. 得到文档 d (词的序列)

neural learning model algebra matrix theorem network ... empire history war king ...

Plate Notation (概率图模型表示)



符号说明

- α Dirichlet 超参数 (文档-主题分布的先验)
- θ_d 第 d 篇文档的主题混合比例 (K 维向量)
- $z_{d,n}$ 文档 d 中第 n 个词的主题分配 (取值 $1 \dots K$)
- $w_{d,n}$ 文档 d 中第 n 个词 (观测到的词)
- β_k Dirichlet 超参数 (主题-词分布的先验)
- ϕ_k 第 k 个主题的词分布 (V 维向量, V 为词表大小)


- K : 主题总数
- D : 文档总数
- N_d : 文档 d 的词数
- V : 词表大小

核心思想


每篇文档由多个主题按比例混合;
每个词先从文档的主题分布中选择一个主题,
再从该主题的词分布中生成。

LDA 的训练过程 (逆过程: 推断与参数优化)


0. 观测数据 (语料库)




1. 隐变量 (未知)



2. 参数 (未知)




3. 目标: 最大化观测数据的似然




4. 通过贝叶斯推断更新信念 (两种主流方法)


4A. 吉布斯采样 (Gibbs Sampling) —— 用随机采样近似后验




收敛后: 样本近似来自后验分布 $P(Z, \theta, \beta | W, \alpha)$



4B. 变分推理 (Variational Inference) —— 用优化近似后验



收敛后: 得到最优近似分布 $q^*(Z, \theta, \beta) \approx P(Z, \theta, \beta | W, \alpha)$



3. 神经/深度学习类 (VAE-based NTM, NVDM, ETM)

现实是深度非线性、可优化函数空间
(复杂模式涌现)

实体：潜变量向量、网络参数
主题 = 潜空间中的区域/方向
(端到端学出，事后提取)

提取：通过端到端梯度优化
(ELBO等) 学习
证成：重建质量 + 下游任务

优：端到端优化框架严谨
劣：主题定义较松散，依赖经验解释

$$\theta_d \sim \mathcal{N}(\mu_d, \sigma_d^2), \text{ for } d \in D$$

$$z_n \sim \text{Multi}(\theta_d), \text{ for } n \in [1, N_d]$$

$$w_n \sim \text{Multi}(\text{Decoder}(z_n)), \text{ for } n \in [1, N_d]$$

• μ_d, σ_d^2 : Encoder 输出的均值和标准差 (用来定义一个高斯分布)。

• $\theta_d \sim \mathcal{N}(\mu_d, \sigma_d^2)$: 文档的主题表示 θ_d 服从正态分布 (Gaussian/Normal 分布), 由 Encoder 决定参数。

• $d \in D$: 对所有文档 D 中的每一篇文档 d 。


• $z_n \sim \text{Multi}(\theta_d)$: 为第 n 个词抽取主题 (同 LDA)。

• $w_n \sim \text{Multi}(\text{Decoder}(z_n))$: Decoder (神经网络) 根据主题 z_n 生成词的概率分布, 再从中抽取词 w_n 。


• N_d : 第 d 篇文档的词总数。

基于VAE的神经主题模型 (NTM) —— 以 NVDM 为例


1. 总体架构 (VAE 框架)



2. 生成过程 (与 LDA 的区别)



3. 与 LDA 的核心区别 (改进点)



4. 变分推断与目标函数 (ELBO)

用变分分布 $q_\phi(\theta_d|d)$ 近似真实后验 $p(\theta_d|d)$

编码器输出

重参数化采样

ELBO 目标函数 (最大化)

$$\mathcal{L} = \mathbb{E}_{q_\phi(\theta_d|d)} [\log p(d|\theta_d)] - D_{KL}(q_\phi(\theta_d|d) \| p(\theta_d))$$

重构项
(生成文档的对数似然)

正则项 (KL散度)
(约束接近先验)

$$p(\theta_d) = \mathcal{N}(0, I)$$

5. 编码器与解码器结构 (NVDM 实现)

Encoder $q_\phi(\theta_d|d)$

文档词袋向量 $x_d \in \mathbb{R}^V$

$x_1, x_2, x_3, \dots, x_V$



$\mu_d \in \mathbb{R}^K$ $\sigma_d \in \mathbb{R}^K$

$$\epsilon \sim \mathcal{N}(0, I)$$

$$\theta_d = \mu_d + \sigma_d \odot \epsilon$$

Decoder $p_\theta(w|z)$

主题-词分布 (条件于主题 z)

主题 z_1

主题 z_2

$\vdots$

主题 z_K

词分布
 $p(w|z)$

词表 V

6. 训练流程 (最大化 ELBO)

输入文档批次
(词袋向量)

Encoder 前向传播
得到 μ_d, σ_d

重参数化采样
得到 θ_d

Decoder 生成词分布
计算重构损失

计算 KL 散度
与先验对齐

反向传播
更新参数

总结: NTM (以 NVDM 为例) 的改进与优势



连续潜空间: 用高斯分布建模文档主题表示, 表达能力更强。



神经生成器: Decoder 用神经网络建模主题-词分布, 捕获非线性语义关系。



变分推断: VAE 框架可扩展, 能处理大规模语料和复杂先验。



更好的泛化: 通过正则化 (KL 散度) 避免过拟合, 提升主题质量。

生成过程公式 (NVDM)

$$\theta_d \sim \mathcal{N}(\mu_d, \sigma_d^2 I)$$

$$z_n \sim \text{Multi}(\theta_d) \quad \text{for } n \in [1, N_d]$$

$$w_n \sim \text{Multi}(\text{Decoder}(z_n)) \quad \text{for } n \in [1, N_d]$$

核心理念



用神经网络 (Encoder + Decoder) 学习概率潜空间,
将传统主题模型与深度学习结合, 实现更灵活、强大的主题发现能力。

应用场景



短文本建模



语义搜索



推荐系统



文本生成



多模态融合

...

4. 嵌入-聚类-表示类 现实是连续的语义向量空间
(Top2Vec, BERTopic) (几何关系、分布式表征)

实体：嵌入向量、聚类簇
主题 = 嵌入空间中的聚类 +
TF-IDF权重词列表 (事后提取)

提取：通过预训练嵌入 + 聚类
发现潜在空间结构
证成：聚类质量 + 主题质量


优：模块化流水线逻辑，灵活
劣：错误传递、上游依赖；接口处可能不完全一致

$$e_d = \text{Encoder}_{\text{BERT}}(d), \text{ for } d \in D$$


$$\text{Cluster}(\{e_d\}) \rightarrow \{\text{Topic}_k\}$$

$$\text{Topic}_k = c\text{TFIDF}(w \mid C_k)$$

嵌入-聚类-表示类流水线方法（以 BERTopic 为例）



c-TF-IDF 如何计算 (以主题簇 C_k 为例)



5. LLM主题建模类 (Prompt-based, TopicGPT)

现实是语言中心、可叙述的知识投射
(LLM已编码的世界理解)

实体：文档、LLM内部知识
主题 = 自然语言对象 (名字 +
详细描述 + 证据引用)

提取：通过提示工程 + 上下文
学习直接查询
证成：人类判断 + 可验证引用

优：对话式/启发式逻辑，灵活且可解释
劣：稳定性依赖提示词，幻觉

$$Topic_k = LLM(Prompt(Sample(D), Instructions))$$

$$e_d = Encoder_{BERT}(d), \text{ for } d \in D$$

$$Cluster(\{e_d\}) \rightarrow \{Topic_k\}$$

$$Topic_k = LLM(C_k)$$

$$Topic_k = LLM(Retrieve(D))$$


$$Topic_k = Agent(Retrieve(D))$$

LLM 时代的主题建模方法谱系

核心思想：用 LLM 的语言理解与生成能力，从“发现主题”演化为“解释主题、验证主题、迭代化主题”

大學
CHNOLOGY

1 Prompt 主题建模 (TopicGPT 类)



2 聚类 + LLM 标注 (主流工业方案)



3 RAG 主题建模 (面向大规模语料)



4 Agentic 主题建模 (迭代式优化)



共同特点

基于 LLM 的语言理解与生成

输出为自然语言 (名称 + 描述 + 证据)

可解释、可定制、可交互

适应不同规模与任务需求

03 投稿经历分享

Experience Sharing



组别	Metaphysics (形而上学: 现实假设)	Ontology (本体论: 实体与主题表示)	Epistemology (认识论: 知识获取与证成)	Formal Logic (形式逻辑: 自洽性)
1. 代数/矩阵分解类 (LSA, NMF)	现实是线性、可还原的低维结构 (固定本质维度, 噪声+高维投影)	实体: 词、文档、潜在因子 主题 = 固定权重向量 (线性/非负组合)	提取: 通过一次性数学分解 (SVD/NMF) 证成: 靠重构误差	优: 高度自洽 (线性代数公理) 劣: 假设矩阵低秩, 简化语言复杂性, 词袋假设简化现实
2. 概率图模型类 (pLSA, LDA)	现实是概率生成的过程 (随机采样驱动, 存在隐藏生成规律)	实体: 文档(θ)、主题(z)、词(w)、先验(α, β) 主题 = 词的概率分布 (Dirichlet控制)	提取: 通过贝叶斯推理 (Gibbs/Variational) 更新信念 证成: Perplexity + Coherence	优: 极强概率逻辑闭环 (生成故事+后验) 劣: 词袋假设简化现实
3. 神经/深度学习类 (VAE-based NTM, NVDM, ETM)	现实是深度非线性、可优化函数空间 (复杂模式涌现)	实体: 潜变量向量、网络参数 主题 = 潜空间中的区域/方向 (端到端学出, 事后提取)	提取: 通过端到端梯度优化 (ELBO等) 学习 证成: 重建质量 + 下游任务	优: 端到端优化框架严谨 劣: 主题定义较松散, 依赖经验解释
4. 嵌入-聚类-表示类 (Top2Vec, BERTopic)	现实是连续的语义向量空间 (几何关系、分布式表征)	实体: 嵌入向量、聚类簇 主题 = 嵌入空间中的聚类 + TF-IDF权重词列表 (事后提取)	提取: 通过预训练嵌入 + 聚类发现潜在空间结构 证成: 聚类质量 + 主题质量	优: 模块化流水线逻辑, 灵活 劣: 错误传递、上游依赖; 接口处可能不完全一致
5. LLM主题建模类 (Prompt-based, TopicGPT)	现实是语言中心、可叙述的知识投射 (LLM已编码的世界理解)	实体: 文档、LLM内部知识 主题 = 自然语言对象 (名字 + 详细描述 + 证据引用)	提取: 通过提示工程 + 上下文学习直接查询 证成: 人类判断 + 可验证引用	优: 对话式/启发式逻辑, 灵活且可解释 劣: 稳定性依赖提示词, 幻觉

04 学术写作交流

Academic Writing





重视写作的审稿人/编辑：

- 英文母语者
- 非计算机背景

重视方法的审稿人/编辑：

- 计算机背景
- AI一键审稿

逐章节检查项：


- 区分主被动：we 突出原创贡献；事实都用被动语态
- 时态一致性、单复数、冠词

Introduction章节：

- 重视段落之间的整体逻辑性、段落内部句子间的连贯性

其他章节（没有页数要求的期刊）：

- 如果有多个子节，需要先在线首讲解整个章节的布局，然后在子节之间添加一句过渡（写在下一个子节开头）



THANKS FOR LISTENING
再见

北京理工大学
BEIJING INSTITUTE OF TECHNOLOGY